

河南大学数学与统计学院 2024 级统计学专业全班五十米跑成绩的抽样估计研究

2010100162 张瑞琦

摘要

为实现高校体质测试核心指标的精准抽样估计，本文以河南大学数学与统计学院 2024 级统计学专业 81 名本科生为研究总体，以五十米跑时长为目标变量，立定跳远为辅助变量，基于不放回简单随机抽样原则抽取 37 份有效样本，分别采用简单估计、比估计、回归估计三种方法对总体五十米跑时长进行估计，并比较三种方法的精确性与有效性。研究结果表明：在总体规模 81、百分之九十五置信度、绝对误差限度 0.02 下样本个数 37 满足需求，且三种估计中回归估计精度最高，简单估计次之，比估计精度最低。

关键词：抽样估计、五十米跑、简单估计、比估计、回归估计

一、问题背景

高校体质健康测试是监测学生身体素质、评估体育教学效果的重要手段。其中，五十米跑作为反映速度与爆发力的核心指标，被广泛纳入体测体系。然而，在实际测试中，受限于时间、人力、场地等资源约束，往往难以对所有学生进行全面测试，通常需要采用抽样调查的方法来估计总体参数。如何以较小的样本量实现高精度的估计，成为提升体测效率与科学性的关键问题。

立定跳远作为同样反映下肢爆发力的测试项目，与五十米跑成绩存在较强的相关性。若能利用这一辅助信息构造更为有效的估计量（如比估计或回归估计），有望在相同样本量下降低估计误差，提高推断精度。

然而，现有研究多聚焦于体测指标的描述性分析或群体差异比较，缺乏对关键指标抽样估计方法的系统比较，尤其是在小规模总体中基于辅助信息进行精确估计的实证研究尚不充分。为此，本文以河南大学数学与统计学院 2024 级统计学专业 81 名本科生为研究总体，以五十米跑时长为目标变量、立定跳远为辅助变量，基于不放回简单随机抽样方法，分别采用简单估计、比估计和回归估计进行总体均值估计，并比较三种方法的精确性与有效性，旨在为高校体质测试核心指标的高效抽样设计提供方法依据。

二、问题分析

2.1 样本量是否满足精度要求？

在总体 $N=81$ 人、置信度 $1-\alpha=95\%$ 、绝对误差 $d=0.02$ 的条件下，依据公式

$$\frac{1}{n} = \frac{1}{N} + \frac{d^2}{z_{\alpha/2}^2 S^2}$$

得出样本量 $n=37$ ，其中参考中国大学生体质健康相关研究中 50m 跑成绩的标准差（约 0.5 - 0.7 秒），考虑性别差异带来的总体波动，取总体标准差 $\sigma=0.8$ 秒作为保守估计，用于样本量计算。

2.2 如何利用辅助变量提高估计效率？

立定跳远与五十米跑时长相关性强，可作为辅助变量。采用比估计和回归估计，预期比简单估计获得更高精度。

2.3 哪种方法最优？

在相同样本数据下，比较三种估计方法的方差或相对效率，确定精度最高的估计方式。

三、三种估计方式对于总体均值的估计

3.1 简单估计

由简单随机抽样性质可知，样本均值可直接作为总体均值的无偏估计量，且总体均值的近似置信区间为

$$[\bar{y} - z_{\alpha/2} \sqrt{\frac{1-f}{n}} s, \bar{y} + z_{\alpha/2} \sqrt{\frac{1-f}{n}} s],$$

代入数据 $\bar{y}=9.73027$ ， $z_{\alpha/2}=1.96$ ， $f=\frac{n}{N}$ ， $n=37, N=81, s^2=3.190069$

得到简单估计在置信度 95% 下的置信区间为[9.30611,10.15444]。

3.2 比估计

根据公式

$$\widehat{\bar{Y}}_R = \bar{y}_R = \bar{X} \frac{\bar{y}}{\bar{x}}$$

可直接得出总体均值 $\bar{Y}$ 的比值估计量 $\widehat{\bar{Y}}_R=9.67311$ 。

又总体均值的近似置信区间为

$$[\bar{y}_R - z_{\alpha/2} \sqrt{\frac{1-f}{n} (s^2 - 2\hat{R}s_{yx} + \hat{R}^2 s_x^2)}, \bar{y}_R + z_{\alpha/2} \sqrt{\frac{1-f}{n} (s^2 - 2\hat{R}s_{yx} + \hat{R}^2 s_x^2)}]$$

代入相关数据，得到比估计在置信度 95% 下的置信区间为[8.87337,10.58718]。

3.3 回归估计

根据公式

$$\overline{y_{lr}} = \bar{y} + b(\bar{X} - \bar{x})$$

其中

$$b = \frac{s_{yx}}{s_x^2} = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

为回归系数。

代入相关数据，得到总体均值 $\bar{Y}$ 的回归估计量 $\overline{y_{lr}}=9.76864$ 。

四、三种估计方法的比较

4.1 大体分析

因为样本个数 37 相对于总体个数 81 来说属于“大样本”数据，故在普遍结论下，回归估计的结果优于简单估计。


对于比估计，由于

$$V(\overline{y_R}) \approx \frac{1-f}{n}(S^2 - 2R\rho SS_x + S^2 S_x^2),$$

$$V(\bar{y}) = \frac{1-f}{n}S^2,$$

用样本方差估计总体方差，得到 $V(\overline{y_R})-V(\bar{y})>0$ ，故简单估计较比估计更为精确。

4.2 直观表示



4.3 总体结论

在本研究数据条件下，回归估计的精度最高（标准误最小、置信区间最窄），简单估计次之，比估计的精度最低。回归估计相对于简单估计的相对效率大于1，表明利用立定跳远作为辅助变量能够有效提高估计精度；而比估计的相对效率小于1，其估计效果甚至劣于不使用辅助信息的简单估计。

在百分之九十五置信度下，回归估计给出的置信区间最短，估计量最稳定，是最适合本研究的估计方法。

立定跳远与五十米跑时长虽存在较强的负相关关系，但并非任何利用辅助变量的估计方法都能提高精度。方法的选择必须考虑数据本身的内在结构特征。

五、结果分析

三种估计方法出现上述精度差异的原因如下：

5.1 回归估计精度最高

回归估计能够根据样本数据自动确定立定跳远与五十米跑时长之间的最优线性关系，且不要求两者的关系曲线通过原点。由于立定跳远与五十米跑时长之间存在较强的负相关关系，回归估计能够最大限度地利用这一辅助信息，从而有效降低估计误差，因此精度最高。

5.2 简单估计精度居中

简单估计仅使用五十米跑时长自身的样本信息，未利用立定跳远这一辅助变量。该方法虽然稳健，但无法借助变量间的相关性来提高估计精度，因此效果介于两者之间。

5.3 比估计精度最低

比估计的核心假设是目标变量与辅助变量的比值为常数，即两者的关系曲线必须严格通过原点。然而，本研究中五十米跑时长不可能随着立定跳远趋近于零而趋近于零，实际数据存在一个正常数截距。这一假设的违背导致比估计产生系统性偏差，估计误差反而大于简单估计，因此精度最低。

小结

辅助变量能否有效提高估计精度，取决于估计方法的选择是否与数据本身的结构特征相匹配。当变量间的关系曲线不通过原点时，回归估计最为适用，而比估计可能产生适得其反的效果。在高校体测数据中，体能指标通常具有明确的下限，变量间关系往往存在截距，因此回归估计一般是比估计更优的选择。

六、符号说明

符号	含义	单位	参数值
N	总体规模	人	81
n	样本量	人	37
f	抽样比	无	$\frac{81}{37}$
$\bar{y}$	样本均值	秒	9.73027

$\bar{Y}$	总体均值	秒	\
$\widehat{\bar{Y}}_R$	总体均值的比估计量	秒	\
$\widehat{\bar{y}}_R$	样本均值的比估计量	秒	\
$\bar{X}$	辅助变量总体均值	厘米	189.26
$\bar{x}$	辅助变量样本均值	厘米	190.3784
d	绝对误差限度	无	0.2
$z_{\alpha/2}$	标准正态分布分位数	无	1.96(95%)
S^2	总体方差	无	\
s^2	样本方差	无	3.190069
S	总体标准差	无	\
s	样本标准差	无	\
s_{yx}	辅助变量和目标变量 的协方差	无	-55.1109
S_x^2	辅助变量总体方差	无	\
s_x^2	辅助变量样本方差	无	1606.186
R	总体比率	无	\
ρ	相关系数	无	-0.7699
b	回归系数	无	$\frac{s_{yx}}{s_x^2}$
$\bar{y}_{lr}$	总体均值的回归估计 量	无	$\bar{y} + b(\bar{X} - \bar{x})$
$\hat{R}$	总体比率的估计值	无	$\frac{\bar{y}}{\bar{x}}$
x_i	第 i 个辅助变量样本	厘米	\
y_i	第 i 个样本	秒	\

七、参考文献

- [1] 《抽样技术（第五版）》金勇进编，中国人民大学出版社.
- [2] 《学生体质健康标准》制定工作实证研究的抽样方案实施与测试数据统计处理实务[J].

北京体育大学学报, 2006, (09).

[3] 袁存柱. 海南省大学生 50m 跑与立定跳远间运动技能和运动素质迁移的研究(I)[J]. 海南师范学院学报(自然科学版), 2002, (Z1).

[4] 叶高亮. 基于主成分回归分析模型的大学生体质评估[D]. 南昌: 南昌大学, 2020.

八、附录

8.1 AI 使用说明

本文仅在结论分析和绘图部分使用了 AI 协助完成, 所有数据均通过 Excel 函数公式计算得到, 其他文本部分由作者独立完成。

8.2 绘图代码 (python)

```
import numpy as np
import matplotlib.pyplot as plt
import math

plt.rcParams['font.sans-serif'] = ['SimHei']
plt.rcParams['axes.unicode_minus'] = False

print("=== 三种估计方法精度比较程序 ===\n")

n = float(input("样本量 n = "))
N = float(input("总体规模 N = "))

z = 1.96

y_bar = float(input("样本目标变量均值  $\bar{y}$  = "))
s2_y = float(input("样本目标变量方差  $s_y^2$  = "))
x_bar = float(input("样本辅助变量均值  $\bar{x}$  = "))
s2_x = float(input("样本辅助变量方差  $s_x^2$  = "))
s_xy = float(input("样本协方差  $s_{xy}$  = "))
X_bar = float(input("总体辅助变量均值  $\bar{X}$  = "))

f = n / N

FPC = 1 - f
```



```

var_simple = FPC / n * s2_y
se_simple = math.sqrt(var_simple)
CI_simple = [y_bar - z * se_simple, y_bar + z * se_simple]
R_hat = y_bar / x_bar
y_bar_ratio = R_hat * X_bar
var_ratio = FPC / n * (s2_y + R_hat**2 * s2_x - 2 * R_hat * s_xy)
se_ratio = math.sqrt(var_ratio)
CI_ratio = [y_bar_ratio - z * se_ratio, y_bar_ratio + z * se_ratio]
b = s_xy / s2_x
y_bar_reg = y_bar + b * (X_bar - x_bar)
var_reg = FPC / n * (s2_y - s_xy**2 / s2_x)
se_reg = math.sqrt(var_reg)
CI_reg = [y_bar_reg - z * se_reg, y_bar_reg + z * se_reg]
print("\n" + "="*60)
print("估计结果汇总")
print("="*60)
print(f"{'方法':<8} {'点估计':<12} {'标准误':<12} {'95%置信区间'}")
print("-"*60)
print(f"简单估计   {y_bar:<12.4f} {se_simple:<12.4f} [{CI_simple[0]:.4f}, {CI_simple[1]:.4f}]")
print(f"比估计     {y_bar_ratio:<12.4f} {se_ratio:<12.4f} [{CI_ratio[0]:.4f}, {CI_ratio[1]:.4f}]")
print(f"回归估计   {y_bar_reg:<12.4f} {se_reg:<12.4f} [{CI_reg[0]:.4f}, {CI_reg[1]:.4f}]")
print("="*60)
eff_ratio = var_simple / var_ratio
eff_reg = var_simple / var_reg
print(f"\n 相对效率（以简单估计为基准）:")
print(f"比估计相对效率 = {eff_ratio:.2f}（方差是简单估计的 {1/eff_ratio:.2f} 倍）")
print(f"回归估计相对效率 = {eff_reg:.2f}（方差是简单估计的 {1/eff_reg:.2f} 倍）")
if eff_ratio > 1:
    print(f"✓ 比估计比简单估计精度提高了 {(eff_ratio-1)*100:.1f}%")

```

```

if eff_reg > 1:
    print(f"✓ 回归估计比简单估计精度提高了 {(eff_reg-1)*100:.1f}%")

fig = plt.figure(figsize=(14, 10))

fig.suptitle(f'三种估计方法精度对比 (n={int(n)}, N={int(N)}, 置信度 95%) ', fontsize=14,
fontweight='bold')

methods = ['简单估计', '比估计', '回归估计']

estimates = [y_bar, y_bar_ratio, y_bar_reg]

se_values = [se_simple, se_ratio, se_reg]

CI_width = [CI_simple[1]-CI_simple[0], CI_ratio[1]-CI_ratio[0], CI_reg[1]-CI_reg[0]]

rel_eff = [1, eff_ratio, eff_reg]

CV_values = [se_simple/y_bar*100, se_ratio/y_bar_ratio*100, se_reg/y_bar_reg*100]

all_CIs = [CI_simple, CI_ratio, CI_reg]

plt.subplot(2, 3, 1)

bars = plt.bar(methods, estimates, color=['#4472C4', '#ED7D31', '#A5A5A5'])

plt.errorbar(methods, estimates, yerr=[z*se for se in se_values], fmt='none', color='black',
capsize=5)

plt.ylabel('估计值')

plt.title('点估计与 95%置信区间')

plt.grid(True, alpha=0.3)

for bar, val in zip(bars, estimates):
    plt.text(bar.get_x() + bar.get_width()/2, bar.get_height() + 0.01, f'{val:.4f}', ha='center',
va='bottom')

plt.subplot(2, 3, 2)

bars = plt.bar(methods, se_values, color=['#4472C4', '#ED7D31', '#A5A5A5'])

plt.ylabel('标准误 (SE)')

plt.title('估计精度对比 (标准误越小越好) ')

plt.grid(True, alpha=0.3)

for bar, val in zip(bars, se_values):
    plt.text(bar.get_x() + bar.get_width()/2, bar.get_height() + 0.001, f'{val:.4f}', ha='center',
va='bottom')

```

```

plt.subplot(2, 3, 3)

bars = plt.bar(methods, CI_width, color=['#4472C4', '#ED7D31', '#A5A5A5'])

plt.ylabel('置信区间宽度')

plt.title('区间宽度对比（越窄精度越高）')

plt.grid(True, alpha=0.3)

for bar, val in zip(bars, CI_width):

    plt.text(bar.get_x() + bar.get_width()/2, bar.get_height() + 0.002, f'{val:.4f}', ha='center',
va='bottom')

plt.subplot(2, 3, 4)

bars = plt.bar(methods, rel_eff, color=['#4472C4', '#ED7D31', '#A5A5A5'])

plt.axhline(y=1, color='red', linestyle='--', linewidth=1.5, label='基准线(简单估计=1)')

plt.ylabel('相对效率')

plt.title('相对效率对比（>1 表示精度更高）')

plt.grid(True, alpha=0.3)

plt.legend()

for bar, val in zip(bars, rel_eff):

    plt.text(bar.get_x() + bar.get_width()/2, bar.get_height() + 0.02, f'{val:.2f}', ha='center',
va='bottom')

plt.subplot(2, 3, 5)

bars = plt.bar(methods, CV_values, color=['#4472C4', '#ED7D31', '#A5A5A5'])

plt.ylabel('变异系数 CV (%)')

plt.title('变异系数对比（越小越稳定）')

plt.grid(True, alpha=0.3)

for bar, val in zip(bars, CV_values):

    plt.text(bar.get_x() + bar.get_width()/2, bar.get_height() + 0.2, f'{val:.2f}%', ha='center',
va='bottom')

plt.subplot(2, 3, 6)

y_pos = [3, 2, 1]

colors = ['#4472C4', '#ED7D31', '#A5A5A5']

```

```

for i in range(3):

    plt.plot([all_CIs[i][0], all_CIs[i][1]], [y_pos[i], y_pos[i]], color=colors[i], linewidth=3)

    plt.plot([all_CIs[i][0], all_CIs[i][0]], [y_pos[i]-0.1, y_pos[i]+0.1], color=colors[i], linewidth=2)

    plt.plot([all_CIs[i][1], all_CIs[i][1]], [y_pos[i]-0.1, y_pos[i]+0.1], color=colors[i], linewidth=2)

    plt.plot(estimates[i], y_pos[i], 'o', color='black', markersize=8, markerfacecolor='black')

plt.yticks(y_pos, methods)

plt.ylabel('估计方法')

plt.xlabel('估计值')

plt.title('95%置信区间可视化（线段越短精度越高）')

plt.grid(True, alpha=0.3)

plt.tight_layout()

plt.show()

print("\n" + "="*60)

print("精度排名与建议")

print("="*60)

sorted_idx = np.argsort(se_values)

print("按标准误（越小越好）排名：")

for i, idx in enumerate(sorted_idx):

    print(f" {i+1}. {methods[idx]} (SE={se_values[idx]:.4f})")

best_idx = np.argmin(se_values)

print(f"\n★ 推荐使用：【{methods[best_idx]}】精度最高！")

print("="*60)

```